

ΠΑΝΕΠΙΣΤΗΜΙΟ ΙΩΑΝΝΙΝΩΝ
ΤΜΗΜΑ ΜΗΧ. Η/Υ & ΠΛΗΡΟΦΟΡΙΚΗΣ

Προχωρημένα Θέματα Τεχνολογίας και Εφαρμογών Βάσεων Δεδομένων
ΜΥΕ030 / ΠΛΕ045

ΠΡΟΓΡΑΜΜΑΤΙΣΤΙΚΗ ΕΡΓΑΣΙΑ
ΓΙΑ ΤΟ ΑΚΑΔΗΜΑΪΚΟ ΕΤΟΣ 2025-
2026

BIBLIOGRAPHIC DATA
INTEGRATION & VISUALIZATION

ΘΕΟΦΑΝΗΣ ΤΟΜΠΟΛΗΣ, ΑΜ: 4855

ΑΘΑΝΑΣΙΟΣ ΦΥΤΙΛΗΣ, ΑΜ: 5381

ΜΑΡΙΝΟΣ ΑΡΙΣΤΕΙΔΟΥ, ΑΜ: 5397

ΤΕΛΙΚΗ ΑΝΑΦΟΡΑ

ΜΑΪΟΣ 2026

ΙΣΤΟΡΙΚΟ ΠΡΟΗΓΟΥΜΕΝΩΝ ΕΚΔΟΣΕΩΝ

Το κείμενο συμπληρώνεται προοδευτικά, όπως προχωρούν οι φάσεις του project.

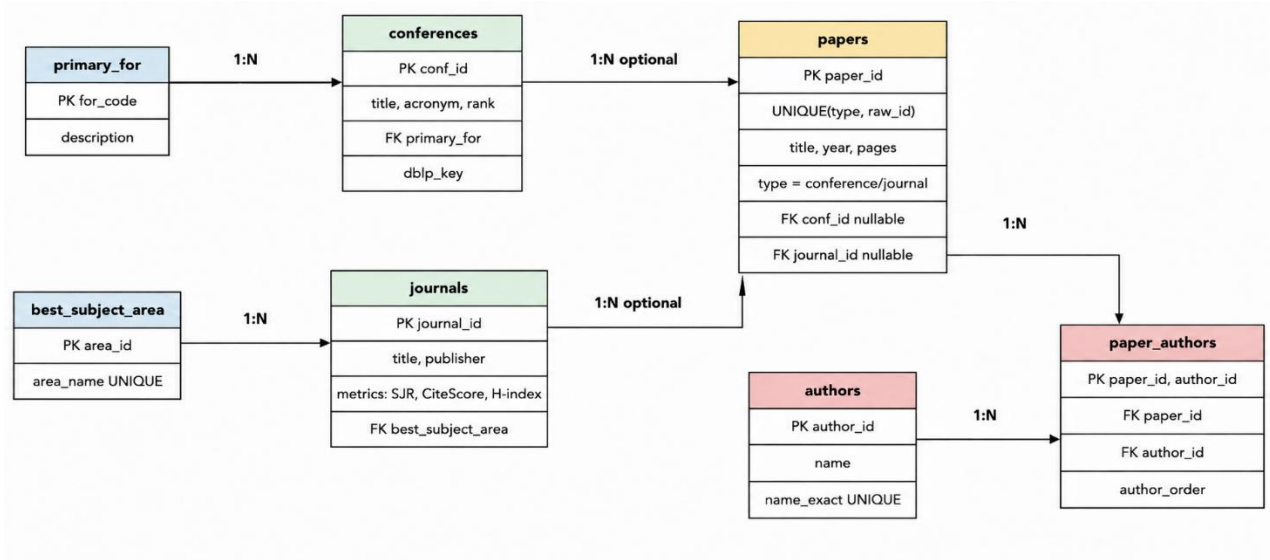
Ημερομηνία	Έκδοση	Περιγραφή	Συγγραφέας
2026/05/13	1.0	Πρώτη ολοκληρωμένη τελική αναφορά σύμφωνα με το πρότυπο του μαθήματος.	Ομάδα 4855_5381_5397
2026/05/16	1.1	Διορθώσεις περιεχομένου, προσθήκη QA/validation στοιχείων και screenshots με πραγματικά στιγμιότυπα από το demo.	Ομάδα 4855_5381_5397

1 ΒΑΣΗ ΔΕΔΟΜΕΝΩΝ

Η εφαρμογή BiblioExplorer ενοποιεί βιβλιογραφικά δεδομένα από DBLP, iCORE26 και Kaggle journal rankings σε μία ενιαία σχεσιακή βάση δεδομένων με όνομα biblio_db. Ο σκοπός του σχήματος είναι να κρατήσει καθαρά και επερωτήσιμα factual δεδομένα για δημοσιεύσεις, συγγραφείς και venues, διαχωρίζοντας παράλληλα τα lookup/ranking δεδομένα από τα ίδια τα άρθρα.

1.1 ΣΧΕΣΙΑΚΌ ΣΧΉΜΑ ΣΕ ΛΟΓΙΚΌ ΕΠΊΠΕΔΟ

Το λογικό σχήμα σχεδιάστηκε γύρω από έναν ενοποιημένο factual πίνακα papers. Η βασική σχεδιαστική απόφαση είναι ότι άρθρα συνεδρίων και άρθρα περιοδικών αποθηκεύονται στον ίδιο πίνακα με πεδίο διάκρισης type. Με αυτόν τον τρόπο απλοποιούνται τα author/year analytics και αποφεύγεται η επανάληψη κοινών πεδίων όπως τίτλος, έτος, σελίδες, DBLP key και σύνδεσμοι.



Σχήμα 1.1 Σχηματικό σχήμα της βάσης δεδομένων του συστήματος

Πίνακας	Ρόλος	Κλειδιά / Περιορισμοί
primary_for	Lookup πίνακας για τις κατηγορίες PrimaryFor των συνεδρίων.	PK: for_code
best_subject_area	Lookup πίνακας για τα BestSubjectArea των περιοδικών.	PK: area_id, UNIQUE: area_name
conferences	Κανονικοποιημένες εγγραφές συνεδρίων από iCORE26.	PK: conf_id, FK: primary_for, UNIQUE: acronym
journals	Κανονικοποιημένες εγγραφές περιοδικών από Kaggle με ranking metrics.	PK: journal_id, FK: best_subject_area, UNIQUE: title(191)
authors	Reference table συγγραφέων. Θεωρείται ότι δεν υπάρχουν συνωνυμίες.	PK: author_id, UNIQUE: name_exact, FULLTEXT: name
papers	Factual table για conference papers και journal articles.	PK: paper_id, UNIQUE: (type, raw_id), FK: conf_id/journal_id, CHECK: type-consistent venue
paper_authors	Πίνακας συσχέτισης N:M ανάμεσα σε papers και authors.	PK: (paper_id, author_id), FK: paper_id, author_id, author_order

1.1.1 ΣΧΕΔΙΑΣΤΙΚΕΣ ΑΠΟΦΑΣΕΙΣ ΚΑΙ TRADE-OFFS

- Ενοποιημένος πίνακας papers: μειώνει την πολυπλοκότητα στα author/year queries, αλλά χρειάζεται CHECK constraint ώστε conference rows να μην δείχνουν σε journal_id και journal rows να μην δείχνουν σε conf_id.
- Surrogate integer primary keys: αποφεύγεται η χρήση μεγάλων συμβολοσειρών DBLP ως primary keys και βελτιώνονται οι joins.

- Προαιρετική σύνδεση με venue: αν ένα DBLP booktitle ή journal δεν μπορεί να αντιστοιχιστεί σε ranked venue, το paper παραμένει στη βάση με NULL conf_id ή journal_id. Έτσι δεν χάνεται δραστηριότητα συγγραφέων και ετών.
- Ξεχωριστοί lookup πίνακες για rankings: τα ranking attributes των συνεδρίων/περιοδικών δεν αναμιγνύονται με τα factual paper rows.
- N:M authorship: οι pipe-separated λίστες συγγραφέων μετατρέπονται σε paper_authors, με διατήρηση author_order.

1.1.2 ΕΝΔΕΙΚΤΙΚΟ DDL ΤΟΥ ΤΕΛΙΚΟΎ ΣΧΗΜΑΤΟΣ

```
CREATE TABLE primary_for (
  for_code VARCHAR(20) NOT NULL,
  description VARCHAR(255) NOT NULL,
  PRIMARY KEY (for_code)
) ENGINE=InnoDB;
```

```
CREATE TABLE conferences (
  conf_id INT NOT NULL AUTO_INCREMENT,
  title VARCHAR(512) NOT NULL,
  acronym VARCHAR(50) NOT NULL,
  rank ENUM('A*','A','B','C') DEFAULT NULL,
  primary_for VARCHAR(20) DEFAULT NULL,
  dblp_key VARCHAR(255) DEFAULT NULL,
  PRIMARY KEY (conf_id),
  UNIQUE KEY uq_conf_acronym (acronym),
  KEY idx_conf_rank (rank),
  KEY idx_conf_for (primary_for),
  CONSTRAINT fk_conf_for FOREIGN KEY (primary_for)
    REFERENCES primary_for(for_code)
    ON UPDATE CASCADE ON DELETE SET NULL
) ENGINE=InnoDB;
```

```
CREATE TABLE journals (
  journal_id INT NOT NULL AUTO_INCREMENT,
  title VARCHAR(512) NOT NULL,
  country VARCHAR(100) DEFAULT NULL,
  publisher VARCHAR(255) DEFAULT NULL,
  sjr_index DECIMAL(10,3) DEFAULT NULL,
  cite_score DECIMAL(10,3) DEFAULT NULL,
  h_index INT DEFAULT NULL,
  best_quartile ENUM('Q1','Q2','Q3','Q4') DEFAULT NULL,
  best_subject_area INT DEFAULT NULL,
  total_docs INT DEFAULT NULL,
  total_refs INT DEFAULT NULL,
  total_cites_3y INT DEFAULT NULL,
  citable_docs_3y INT DEFAULT NULL,
  cites_per_doc_2y DECIMAL(10,3) DEFAULT NULL,
  refs_per_doc DECIMAL(10,3) DEFAULT NULL,
  -- DBLP journal name as it appears in input_article.csv (for matching)
  dblp_name VARCHAR(512) DEFAULT NULL,
  PRIMARY KEY (journal_id),
  UNIQUE KEY uq_journal_title (title(191)),
  KEY idx_journal_quartile (best_quartile),
  KEY idx_journal_area (best_subject_area),
  KEY idx_journal_publisher (publisher(100)),
  CONSTRAINT fk_journal_area FOREIGN KEY (best_subject_area)
    REFERENCES best_subject_area(area_id)
    ON UPDATE CASCADE ON DELETE SET NULL
) ENGINE=InnoDB;
```

```
CREATE TABLE authors (
  author_id INT NOT NULL AUTO_INCREMENT,
  -- name keeps the searchable/display form.
  name VARCHAR(512) CHARACTER SET utf8mb4 COLLATE utf8mb4_unicode_ci NOT NULL,
  -- name_exact is the identity key: exact author string, case/accnt sensitive.
```

```

name_exact VARCHAR(512) CHARACTER SET utf8mb4 COLLATE utf8mb4_bin NOT NULL,
PRIMARY KEY (author_id),
UNIQUE KEY uq_author_name_exact (name_exact),
KEY idx_author_name (name),
FULLTEXT KEY ft_author_name (name)
) ENGINE=InnoDB;


```

```

CREATE TABLE papers (
  paper_id INT NOT NULL AUTO_INCREMENT,
  title TEXT NOT NULL,
  year INT NOT NULL,
  pages VARCHAR(50) DEFAULT NULL,
  type ENUM('conference','journal') NOT NULL,
  conf_id INT DEFAULT NULL,
  journal_id INT DEFAULT NULL,
  volume VARCHAR(50) DEFAULT NULL,
  number VARCHAR(50) DEFAULT NULL,
  dblp_key VARCHAR(255) DEFAULT NULL,
  ee VARCHAR(512) DEFAULT NULL,
  url VARCHAR(512) DEFAULT NULL,
  raw_id VARCHAR(255) DEFAULT NULL,
  PRIMARY KEY (paper_id),
  UNIQUE KEY uq_paper_type_raw_id (type, raw_id),
  KEY idx_paper_year (year),
  KEY idx_paper_conf (conf_id),
-- ... (βλ. πλήρες αρχείο στο etl/01_create_schema.sql)

```

1.2 ΣΧΕΣΙΑΚΟ ΣΧΗΜΑ ΣΕ ΦΥΣΙΚΟ ΕΠΙΠΕΔΟ



Η υλοποίηση στοχεύει σε επαναληψιμότητα και αποδοτική εκτέλεση αναλυτικών queries. Το project δοκιμάστηκε σε MariaDB 10.4.32 στο localhost:3307, με MySQL 8-compatible SQL, InnoDB tables, utf8mb4 character set και utf8mb4_unicode_ci collation για ασφαλή αποθήκευση Unicode τίτλων και ονομάτων.

1.2.1 ΡΥΘΜΙΣΗ ΤΩΝ ΠΑΡΑΜΕΤΡΩΝ ΤΟΥ DBMS

- Η βάση biblio_db δημιουργείται από το etl/01_create_schema.sql και τα scripts θεωρούν DB_HOST=localhost, DB_PORT=3307, DB_USER=root, DB_NAME=biblio_db.

- Όλοι οι πίνακες χρησιμοποιούν InnoDB ώστε να υποστηρίζονται foreign keys, cascading rules και transactional φόρτωση.
- Η εφαρμογή χρησιμοποιεί MySQL connection pool. Στο Flask app το pool αρχικοποιείται με pool_size=10 για τα concurrent analytical requests.
- Τα μεγάλα ETL βήματα εκτελούνται batch-wise. Το 07_load_papers.py χρησιμοποιεί batches των 1.000 rows και upsert μέσω UNIQUE(type, raw_id).

1.2.2 ΡΥΘΜΙΣΗ ΤΟΥ ΦΥΣΙΚΟΥ ΣΧΗΜΑΤΟΣ ΤΗΣ ΒΑΣΗΣ ΔΕΔΟΜΕΝΩΝ

Πέρα από τα primary/foreign keys, το project προσθέτει indexes και SQL views ώστε το μεγαλύτερο μέρος της επεξεργασίας να εκτελείται στο DBMS και όχι στη μνήμη της εφαρμογής.

Στο τρέχον local snapshot η βάση περιέχει 2.525.752 papers, 1.403.305 authors και 7.050.510 rows στον paper_authors. Το API /api/stats/overview επιστρέφει επίσης 1.108 conferences και 18.013 journals για το dashboard.

Αντικείμενο	Αρχείο	Σκοπός
vw_conf_yearly_stats / vw_journal_yearly_stats	etl/08_create_views.sql	Paper count, author slots, distinct authors και average authors ανά venue και έτος.
vw_conf_profile / vw_journal_profile	etl/08_create_views.sql	Συγκεντρωτικό profile κάθε venue: first/last year, total papers, distinct authors, averages.
vw_author_profile / vw_author_yearly_stats	etl/08_create_views.sql	Profile συγγραφέα και ετήσιο breakdown conference/journal δημοσιεύσεων.
vw_year_profile	etl/08_create_views.sql	Στατιστικά ανά έτος: papers, distinct venues και authors.
vw_publisher_stats	etl/08_create_views.sql	Στατιστικά publisher και quartile breakdown για bar chart.
vw_category_yearly_conf / vw_category_yearly_journal	etl/08_create_views.sql	Category trends ανά PrimaryFoR ή BestSubjectArea.
FULLTEXT authors.name, journals.title, conferences(title, acronym)	etl/09_search_indexes.sql	Γρήγορη server-side αναζήτηση σε 1.4M+ authors και venues.
idx_paper_conf_year / idx_paper_journal_year	etl/09_performance_optimization.sql	Βελτίωση profile/paper queries ανά venue και εύρος ετών.

1.2.3 ΡΥΘΜΙΣΗ ΑΣΦΑΛΕΙΑΣ

- Τα API queries χρησιμοποιούν parameterized placeholders αντί για string interpolation των user inputs.
- Η αναζήτηση καθαρίζει ειδικούς χαρακτήρες που μπορούν να σπάσουν Boolean Full-Text search.
- Υπάρχει API rate limiting: 100 requests/minute global και 30 requests/minute στα search endpoints.


- Το FLASK_DEBUG ελέγχεται από environment variable ώστε να μην ενεργοποιείται κατά λάθος στο runtime.
- Σε ευαίσθητα endpoints, π.χ. paper search, το backend καταγράφει server-side exception και επιστρέφει γενικό μήνυμα Internal server error αντί για raw traceback.

2 ΑΡΧΙΤΕΚΤΟΝΙΚΉ ΛΟΓΙΣΜΙΚΟΎ

Η εφαρμογή αποτελείται από τρία διακριτά επίπεδα: ETL/data preparation, Flask REST backend και HTML/CSS/JavaScript frontend με D3.js. Η αρχιτεκτονική είναι modular, με Flask Blueprints ανά βασική οντότητα και ξεχωριστά scripts για καθαρισμό, αντιστοίχιση, φόρτωση και validation.

2.1 ΑΡΧΙΤΕΚΤΟΝΙΚΉ ΚΑΙ ΔΟΜΉ ETL

Η ETL διαδικασία είναι πλήρως script-based και εκτελείται σειριακά. Αρχικά καθαρίζονται τα raw DBLP αρχεία, στη συνέχεια φορτώνονται lookup tables από iCORE/Kaggle, μετά γίνεται αντιστοίχιση venues και τέλος φορτώνονται οι δημοσιεύσεις και οι συσχετίσεις συγγραφέων.



Σχήμα 2.1 Τεκμηρίωση των μετασχηματισμών ETL

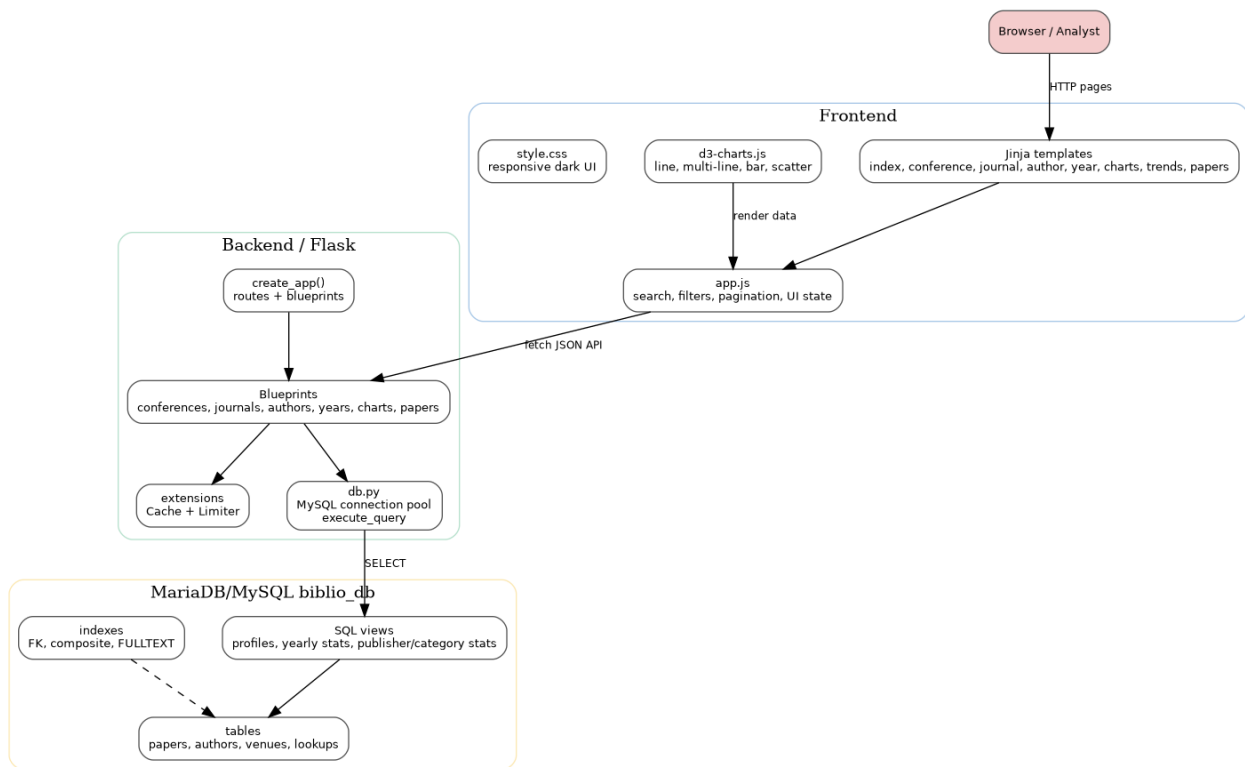
Βήμα	Script	Είσοδος	Έξοδος / αποτέλεσμα
1	etl/01_create_schema.sql	Κενό DBMS schema	Δημιουργεί biblio_db, tables, keys, constraints.
2	etl/02_clean_inproceedings.py	DBLP inproceedings CSV	cleaned_inproceedings.csv και cleaned_inproceedings_authors.csv.
3	etl/03_clean_articles.py	DBLP articles CSV	cleaned_articles.csv και cleaned_articles_authors.csv.
4	etl/04_load_lookups.py	iCORE26, Kaggle, cleaned authors	Φορτώνει primary_for, best_subject_area, conferences, journals, authors.
5	etl/05_match_conferences.py	cleaned booktitles + conferences	booktitle_to_conf_id.csv και review/proposal CSVs.
6	etl/06_match_journals.py	cleaned journal names + journals	journal_name_to_id.csv και alias/review CSVs.
7	etl/07_load_papers.py	cleaned papers + venue mappings + authors	Φορτώνει papers και paper_authors. Κρατά unmatched venues.

8	etl/08_create_views.sql	Loaded biblio_db	Δημιουργεί analytical views.
9	etl/09_search_indexes.sql / 09_performance_optimization.sql	Loaded biblio_db	Προσθέτει FULLTEXT και composite indexes.
10	etl/09_backup.bat	Loaded biblio_db	Λογικό backup σε data/backups/.

2.1.1 ΛΕΠΤΟΜΕΡΕΙΕΣ ΜΕΤΑΣΧΗΜΑΤΙΣΜΩΝ

- Τα required fields για conference papers είναι id, title, year και booktitle. Για journal articles είναι id, title, year και journal.
- Οι συγγραφείς χωρίζονται με delimiter | και μετατρέπονται σε ordered rows με author_order.
- Τα έτη γίνονται αποδεκτά μόνο όταν είναι 4ψήφια. Προβληματικές rows παραλείπονται πριν από τη φόρτωση.
- Στα conferences αξιοποιούνται iCORE metadata, DBLP series keys, manual aliases και conflict/review reports.
- Στα journals γίνεται normalization/abbreviation expansion και overlap matching. Για μικρά ονόματα εφαρμόζεται αυστηρότερο threshold.
- Το τελικό loader ελέγχει ότι υπάρχει UNIQUE(type, raw_id), ώστε το rerun να μη δημιουργεί διπλότυπα facts.

2.2 ΔΙΑΓΡΑΜΜΑΤΑ ΠΑΚ'ΕΤΩΝ / ΥΠΟΣΥΣΤΗΜΑΤΩΝ ΚΕΝΤΡΙΚΗΣ ΕΦΑΡΜΟΓΗΣ




Σχήμα 2.2 Υψηλού επιπέδου αρχιτεκτονική της εφαρμογής

Το backend υλοποιείται με Flask app factory και blueprints. Τα frontend routes σερβίρουν Jinja templates, ενώ τα API routes επιστρέφουν JSON. Η βάση προσπελάζεται αποκλειστικά μέσω helper functions και pooled connections.

Υποσύστημα	Κύρια αρχεία	Λειτουργία
Backend App	backend/app.py	Δημιουργία Flask εφαρμογής, registration blueprints, healthcheck, frontend routes.
DB Access	backend/db.py	Connection pool, context manager cursor, execute_query helper.
Extensions	backend/extensions.py	Flask-Caching και Flask-Limiter.
API Routes	backend/routes/*.py	REST endpoints για conferences, journals, authors, years, charts και papers.
Frontend Templates	frontend/templates/*.html	Σελίδες dashboard, profile, charts, trends και search.
Frontend Logic	frontend/static/js/app.js	Search, autocomplete, filters, pagination, rendering state.
D3 Charts	frontend/static/js/d3-charts.js	Reusable line, multi-line, bar και scatter chart components.
ETL	etl/*.py, etl/*.sql	Καθαρισμός, loading, matching, views, indexes, backup.
Tests	tests/*.py	API shape tests, ETL/matching unit tests, frontend layout checks.

2.3 ΔΙΑΓΡΑΜΜΑΤΑ ΚΛΑΣΕΩΝ / COMPONENTS ΚΕΝΤΡΙΚΗΣ ΕΦΑΡΜΟΓΗΣ

Η κεντρική εφαρμογή δεν είναι αντικειμενοστρεφής με κλασικά domain classes. Είναι κυρίως modular Flask/JavaScript εφαρμογή, επομένως το παρακάτω component diagram αποτυπώνει καλύτερα τη δομή του κώδικα και τις εξαρτήσεις.



Σχήμα 2.3 Component/package diagram του κώδικα

2.3.1 REST API ΚΑΙ ΒΑΣΙΚΑ ENDPOINTS


Endpoint	Περιγραφή	Χρήση στο frontend
GET /health	Έλεγχος σύνδεσης με τη βάση.	Τεχνικός έλεγχος λειτουργίας.
GET /api/conference/search	Αναζήτηση συνεδρίων με filters rank/category/coverage.	Conference search page και comparison autocomplete.
GET /api/conference/<id>/profile	Profile συνεδρίου από views.	Conference profile cards και charts.
GET /api/conference/<id>/papers	Πίνακας δημοσιεύσεων συνεδρίου με year filters.	Profile paper table.
GET /api/journal/search	Αναζήτηση περιοδικών με quartile/subject/publisher/coverage filters.	Journal search page.
GET /api/journal/<id>/profile	Profile περιοδικού και DBLP coverage flag.	Journal profile και no-coverage handling.
GET /api/author/search	Server-side autocomplete σε authors.	Author search page.
GET /api/author/<id>/profile	Profile συγγραφέα και ετήσιο breakdown.	Author profile charts.
GET /api/year/<year>/profile	Συγκεντρωτικό profile χρονιάς.	Year profile.
GET /api/charts/publishers/bar	Publisher quartile breakdown.	Grouped bar chart.
GET /api/charts/scatter/metrics	Journal metrics για scatter plot.	Scatter plot με δύο επιλέξιμες μετρικές.
GET /api/charts/category/conference journal	Category trends ανά PrimaryFoR/BestSubjectArea.	Trends page multi-line charts.
GET /api/paper/search	Cross-venue paper search με venue_type και year filters.	Papers page.

2.3.2 FRONTEND ΚΑΙ ΟΠΤΙΚΟΠΟΙΗΣΕΙΣ



- Line charts: εξέλιξη δημοσιεύσεων, distinct authors και category trends ανά έτος.
- Multi-line charts: σύγκριση πολλαπλών conferences/journals ή conference/journal breakdown συγγραφέα.
- Bar charts: publisher quartile breakdown και venue comparison metrics. Ο άξονας Y ξεκινά από 0.
- Scatter plots: σύγκριση δύο journal metrics, όπως total_docs, citable_docs_3y και sjr_index.
- Responsive UI: CSS breakpoints για μικρές οθόνες, dark-mode μεταβλητές και mobile navigation.

3 ΥΠΟΔΕΪΓΜΑΤΑ ΕΡΩΤΗΣΕΩΝ ΚΑΙ ΑΠΑΝΤΗΣΕΩΝ

Η ενότητα αυτή λειτουργεί σαν σύντομο manual χρήσης του συστήματος και περιλαμβάνει πραγματικά στιγμιότυπα από το live demo: αρχικό dashboard, profile συνεδρίου και advanced charts.



Σχήμα 3.1 Αρχική σελίδα / dashboard με συγκεντρωτικά στατιστικά και χρονοσειρά δημοσιεύσεων



Σχήμα 3.2 Profile συνεδρίου ICDE με rank, κατηγορία, ενεργά έτη και φίλτρα δημοσιεύσεων



Σχήμα 3.3 Advanced charts: publisher quartile grouped bar chart



Σχήμα 3.4 Εξέλιξη του αριθμού δημοσιεύσεων ανά ερευνητική κατηγορία.



Σχήμα 3.5 Εξέλιξη του αριθμού ενεργών συνεδρίων ανά ερευνητική κατηγορία.

3.1 ΕΝΔΕΙΚΤΙΚΕΣ ΕΡΩΤΗΣΕΙΣ ΑΝΑΛΥΤΗ

Ερώτηση χρήστη	Ροή στην εφαρμογή	Απάντηση / αποτέλεσμα
Ποιο είναι το προφίλ του συνεδρίου ICDE;	Conference page -> search ICDE -> επιλογή αποτελέσματος.	Εμφανίζονται rank, PrimaryFoR, first/last year, total papers, distinct authors, line charts και πίνακας papers.
Πόσα papers είχε ένα venue στο διάστημα 2018-2024;	Στο venue profile ο χρήστης δίνει start/end year και πατά Apply.	Ο πίνακας δημοσιεύσεων και τα charts φιλτράρονται στο αντίστοιχο χρονικό εύρος.
Ποια περιοδικά του publisher έχουν Q1/Q2/Q3/Q4 κατανομή;	Charts page -> Publisher Quartile Bar Chart.	Grouped bar chart ανά publisher με τέσσερις σειρές για Q1-Q4.
Πώς σχετίζεται το SJR index με τα citable docs 3y;	Charts page -> Scatter Plot -> επιλογή X/Y metrics.	Κάθε σημείο είναι περιοδικό και χρωματίζεται με βάση το best_quartile.
Τι δημοσίευσε ένας συγγραφέας ανά έτος;	Author page -> autocomplete συγγραφέα.	Profile συγγραφέα, first/last year, total papers, avg papers/year και chart για conference/journal counts.
Τι συνέβη σε μία συγκεκριμένη χρονιά;	Year page -> εισαγωγή έτους.	Πλήθος papers, distinct conferences/journals, author slots, distinct authors και

Πώς εξελίσσονται οι κατηγορίες PrimaryFoR ή BestSubjectArea;

Βρες δημοσιεύσεις με συγκεκριμένο τίτλο ή λέξη-κλειδί.

Trends page -> επιλογή entity type και categories.

Papers page -> search q + optional venue_type/year filters.

πίνακας papers με filters.

Multi-line chart με active venues ή paper_count ανά κατηγορία και έτος.

Πίνακας αποτελεσμάτων με title, year, venue, links DBLP/EE και pagination.

3.2 ΣΥΝΤΟΜΟ MANUAL ΕΚΤΕΛΕΣΗΣ

1. Δημιουργία βάσης: `mysql -u root -P 3307 -e "CREATE DATABASE biblio_db;"` και εκτέλεση `etl/01_create_schema.sql`.
2. Εκτέλεση ETL scripts με τη σειρά 02 έως 09, όπως περιγράφεται στο README.md.
3. Έλεγχος/backup: εκτέλεση `scripts/validate_etl.py` και `etl/09_backup.bat`.
4. Εκκίνηση backend: `python backend/app.py` από το root του project.
5. Άνοιγμα frontend: `http://localhost:5000` και χρήση των διαθέσιμων pages από το navigation bar.

4 ΛΟΙΠΑ ΣΧΟΛΙΑ

4.1 ΈΛΕΓΧΟΣ, ΡΕΠΕΑΤΑΒΙΛΙΤΗ ΚΑΙ ΠΟΙΟΤΗΤΑ ΚΩΔΙΚΑ

- Η επαναληψιμότητα καλύπτεται από DDL scripts, ETL scripts και backup script.
- Το `07_load_papers.py` προστατεύει από διπλοφορτώσεις με identity guard πάνω στο `UNIQUE(type, raw_id)`.
- Υπάρχει test suite για API shape, ETL normalization/matching, lookup loading, venue matching reports και frontend layout checks. Στον τελικό έλεγχο εκτελέστηκε `pytest -q tests` με αποτέλεσμα 125 passed.
- Εκτελέστηκε επίσης `scripts/validate_etl.py`. Τα total paper/author counts, το `UNIQUE(type, raw_id)` guard και τα foreign-key integrity checks πέρασαν. Οι matched/unmatched venue coverage counts διαφέρουν από το παλιό baseline λόγω της νεότερης curation και καταγράφονται στους γνωστούς περιορισμούς.

4.2 ΓΝΩΣΤΟΙ ΠΕΡΙΟΡΙΣΜΟΙ

- Το venue matching είναι best-effort. Τα unmatched venues δεν απορρίπτονται από το factual dataset, αλλά δεν εμφανίζονται στα venue-specific profiles.
- Μερικά journals της Kaggle λίστας μπορεί να έχουν μηδενικό DBLP coverage. Η εφαρμογή τα εμφανίζει με ranking metrics και coverage flag.
- Η φόρτωση των full papers είναι χρονοβόρα. Το `07_load_papers.py` είναι το κυρίαρχο βήμα και διαρκεί περίπου 35 λεπτά για περίπου 2,5M rows.

4.3 ΣΥΜΠΕΡΑΣΜΑΤΑ

Το BiblioExplorer καλύπτει τον βασικό στόχο της εργασίας: μετασχηματίζει ανομοιογενή βιβλιογραφικά δεδομένα σε καθαρή σχεσιακή βάση, παρέχει REST API πάνω σε SQL views/indexes και προσφέρει διαδραστική γραφική διεπαφή για profiles, filters και οπτικοποιήσεις. Η σημαντικότερη τεχνική επιλογή είναι η ενοποίηση των conference και journal publications στον πίνακα papers, με ξεκάθαρη διατήρηση των lookup/ranking tables. Η επιλογή αυτή μειώνει το κόστος των αναλυτικών ερωτημάτων ανά συγγραφέα και χρονιά, ενώ ταυτόχρονα επιτρέπει venue-specific στατιστικά όταν η αντιστοίχιση venue είναι διαθέσιμη.